K+F projekt dokumentáció
ACSG Kft.

Időszak:
2022.09.01. - 2022.10.31.

Készítette: Wenesz Dominik

Tartalomjegyzék

1. Összefoglaló

Az specifikált időintervallumban a kutatásfejlesztési projekt keretén belüli előrehaladásokat, eredményeket, konklúziókat ezen dokumentumban, illetőleg 1-3 hónapos periódusokra lebontva hasonló tematikai felépítéssel kerülnek dokumentálásra.
Ezen beszámolók rövid összefoglalót tartalmaznak, a részletes leírás az egyes részegységek folyamatosan bővülő dokumentációjában található meg, ezen egységek a következők:

- Objektum detektáló alrendszer
- Manipulátor alrendszer
- Optimalizációs alrendszer
- Biztonsági alrendszer
- Grafikus interfész

2022.09.01. - 2022.10.31.:
Az időszakon belül főként az **objektum detektáló alrendszer** elvi felépítésének, alkalmazható algoritmusoknak, hardvereknek milyenségéről végeztünk kutatómunkát.
Továbbá az egyes algoritmusok implementálását, tesztelését is elkezdtük szoftveres környezetben.

A **manipulátor alrendszer** tekintetében egy SCARA robotra esett a választásunk, melynek installálása megtörtént egy elzárt tesztkörnyezetben.

Az **optimaliációs alrendszer** szempontjából érdemi előrehaladás nem történt az időszakban.

A **biztonsági alrendszer** a SCARA robot üzembe helyezése közben a standard ipari robotoknál szokásos részekkel ellátásra került, ezek a végleges rendszer esetében is ilyen formában lesznek implementálva.

A **grafikus interfészt** tekintve koncepcionális tervek születtek.

2. Objektum detektáló alrendszer

Az objektum detektáló alrendszer szempontjából a precizitás és sebesség a két fő aspektus, melyek az esetek többségében együtt csak igen optimális esetben teljesülnek.

Hardver
A kutatásfejlesztés során fontos figyelembe vennünk az egyes algoritmusok tesztelése, összehasonlítása során a beágyazott rendszerek általi limitáltságot, hiszen nem lenne optimális ha a képfeldolgozó rendszer mögött egy nagyteljesítményű PC-t üzemeltetni.
Egyrészt energetikai okokból, másrészt minden bizonnyal egy PC esetében az erőforrások nem lennének teljesen kihasználva, másrészt stabilitási és integritásbeli problémákhoz is vezethet, továbbá invesztálási költségben a tipikus beágyazttrendszerbeli hardverek nagyságrendekkel olcsóbbak.

Ennek megfelelően mivel a feladat számításigénye meglehetősen nagy, egyszerű mikrokontrollerek nem alkalmazhatók, náluk nagyobb teljesítményű úgynevezett single board computer-eket tudunk képfeldolgozási célokra használni. Tekintve, hogy mesterséges intelligenciát is alkalmazni kívánunk valós időben, ezért fontos, hogy a számítások párhzamosan gyorsan végrehajtásra kerüljenek, így megfelelő GPU-val rendelkező eszközre van szükségünk a projektben.

Irodalomkutatás után hasonló alkalmazásokra tipikusan két modellt használnak:

- RASPBERRY PI 4 MODEL B
- NVIDIA JETSON NANO

Számítási teljesítményben, memóriában és I/O tekintetében szinte teljesen megegyeznek egymással, azonban a Jetson Nano az NVIDIA kifejezetten mesterséges intelligencia és képfeldolgozáson alapuló applikációkra fejlesztette ki.
Beruházási költség tekintetében a Jetson Nano nagyjából kétszeres áron kapható, mint a Respberry Pi.
Kapható az NVIDIA által forgalmazott hasonló SBC is, mely jóval nagyobb teljesítménnyel bír főként a sokszor több GPU Core miatt, azonban ezek ára sokszorosa az említett Jeston Nano-nak.

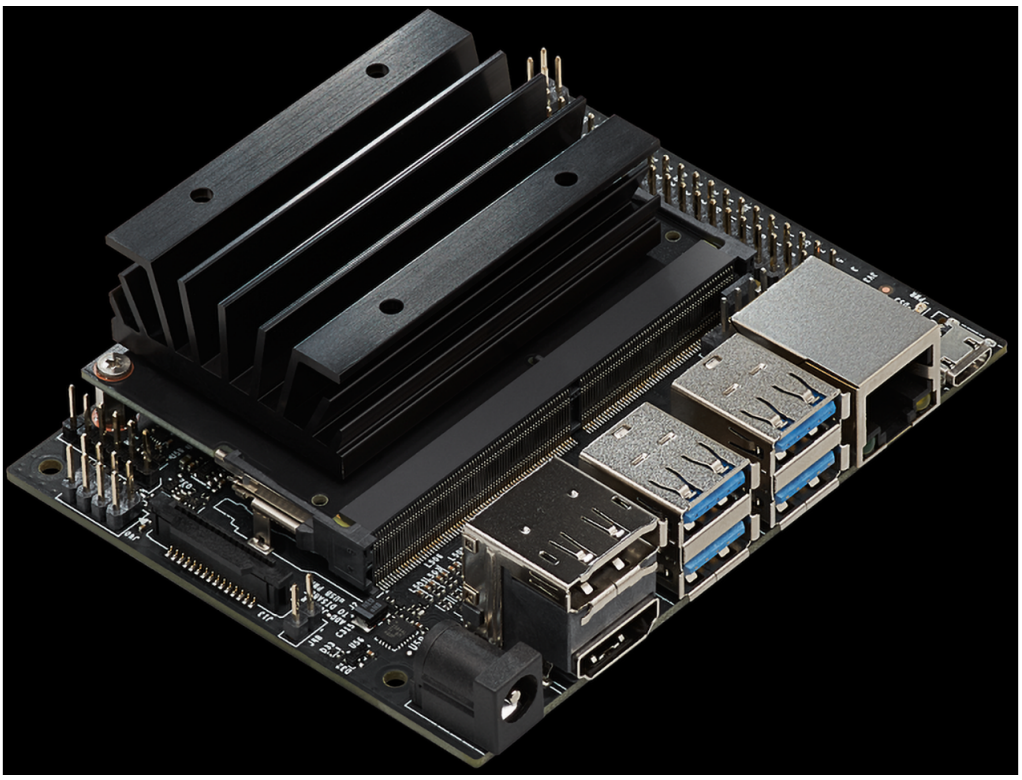

1. ábra. Jetson Nano Developer Kit

Összességében mérlegelést követően a Jetson Nano alkalmazása mellett döntöttünk, hiszen kifejezetten képfeldolgozási feladatokra optimalizálták és bekerülése költsége nem túl nagy, így kicsi a kutatási veszteség ha mégsem alkalmas az applikációhoz, bár ez az eshetőség nem valószínű.

A Jetson Nano teljes adatlapja a csatolmányok közt megtalálható.
Összefoglalva főbb tulajdonságait:

- GPU: 128-core Maxwell
- CPU: Quad-core ARM A57 @ 1.43 GHz
- Memória: 4 GB 64-bit LPDDR4 25.6 GB/s
- I/O: GPIO, UART, SPI, I^2C, I^2S, Gigabit Ethernet, HGMI, USB 3.0, USB 2.0

Természetesen az objektumok detektálásához szükségünk van egy kamerára is.
Jelenlegi tesztjeink során egy Hama webkamerát használunk, de rövidesen le fogjuk cserélni egy Raspberry Pi Camera V2.1 modulra, mely könnyedén csatlakoztatható a Jetson Nano-hoz.
Előnye ezen detektornak, hogy könnyedén cserélhető meghibásodás esetén, könnyen csatlakoztatható több különböző hardverhez is és megfelelő minőségű képet képes továbbítani, továbbá olcsó.

A kamera datlapja szintén megtalálható a mellékletek közt, főbb tulajdonságai:

- Felbontás: 8 Megapixel
- 3280 x 2464 pixel
- Szenzor: Sony IMX219
- Pixelméret: 1.12 µm x 1.12 µm
- Állítható fókusz
- Depth of field: 10cm +

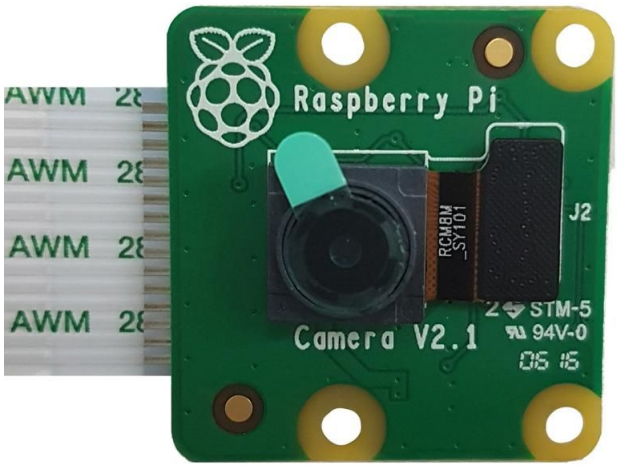

2. ábra. Raspberry Pi Camera v2.1

- Horizontális látószög: 62.2 fok
- Vertikális látószög: 48.48 fok

Amennyiben nem bizonyul elegendőnek a kamera felbontása vagy egyé paramétere, lehetőségünk van két jobb jellemzőkkel rendelkező Raspberry Pi camera modul közül választani.

Szoftver

A standard képfeldolgozás már bevett eszköztárral, kiforrt algoritmusokkal és programozási könyvtárakkal rendelkezik. Ezen eszköztárban találunk több objektum detektálásra szolgáló módszert.
Röviden összefoglalva kimondható, hogy az úgynevezett hagyományos képfeldoglozási módszerek igen hatékonyak, hiszen GPU-ra és CPU-ra is optimalizálva lettek az évek alatt. Az iparban gyakran használt algoritmusokról beszélhetünk, azonban elmondható, hogy a legtöbb ipari környezetbeli installációnál igen limitált szerepet látnak el ezen algoritmusok, szoftverek, hiszen a gyorsaságuknak az ára az egyszerűségük.
Egy példaként lehet említeni ha valamilyen pozíció ellenőrző, minőségbiztosítási rendszerről beszélünk, melyben tegyük fel, hogy egy ismert, egyszerű geometriájú alakzatot vizsgálunk. Ekkor használhatunk különböző él- vagy sarok detektáló, esetleg alakzatdetektáló (pl.: Hough-transzformáció) algoritmusokat. A bejövő kamerakép egy-egy monitorozott ablakán (szubpixeleken) ez működő megoldás, azonban ha akár csak kis sztochasztikus zaj is éri a rendszert, máris hamis eredményeket kaphatunk az ilyen algoritmusokkal, továbbá ha több alakzatot szeretnénk detektálni ismételten problémába ütközünk, nem beszélve arról az eshetőségről ha a detektálni kívánt objektum több eltérő pozícióban, elhelyezkedésben is előfordulhat. Ekkor a kezdeti egyszerű, gyors hagyományos algoritmusunk vagy hatalmasra nő különböző esetek lekezelésére való bővítések során, mely természetesen a végrehajtási időt is megnöveli (sokszor exponenciálisan), vagy egyszerűen nem jutunk eredményre akármennyire is bővítjük a szoftverünket.
Természetesen lehetséges megfontolt modellezéssel egy-egy nagyobb dimenziós problémát kisebb komplexitású problémává rekuálni, például más kameraszög, egyéb szenzorok, stb. Azonban egy másik opció a napjainkban szinte kivétel nélkül minden kutatási területen úttörő mesterséges intelligenciát alkalmazni. Viszonylag kiforrt (de folyamatosan fejlődő) rendszerrel rendelkezik a mélytanulás (deep learning) a képfeldolgozás területén. Ezen megközelítésről a további dokumentációkban részletesen említést teszünk.

A jelen dokumentum által tárgyalt időszakban a probléma hagyományos képfeldolgozás általi megközelítését tartalmazza röviden (részletesen lásd objektum detektálás dokumentációban).

2.1. Él- és sarokdetektálás alapú alakfelismerés

A képfeldolgozásban globális és lokális manipulációk összességével érhető el a kívánt módosítás a digitális képben, melynek eredményeként jelen esetben egyes objektumok jelenlétét és pozícióját tudjuk meghatározni. A legtöbbször előkerülő operáció a konvolúció, mely a képfeldolgozási terminológiát alkalmazva egy súlyozott mátrixot konvolvál (futtat végig és értékel ki) a két dimenziós képen. Fontos megjegyezni, hogy minden csatornára külön fut le a konvolúció. Képen illusztrálva a konvolúciót:

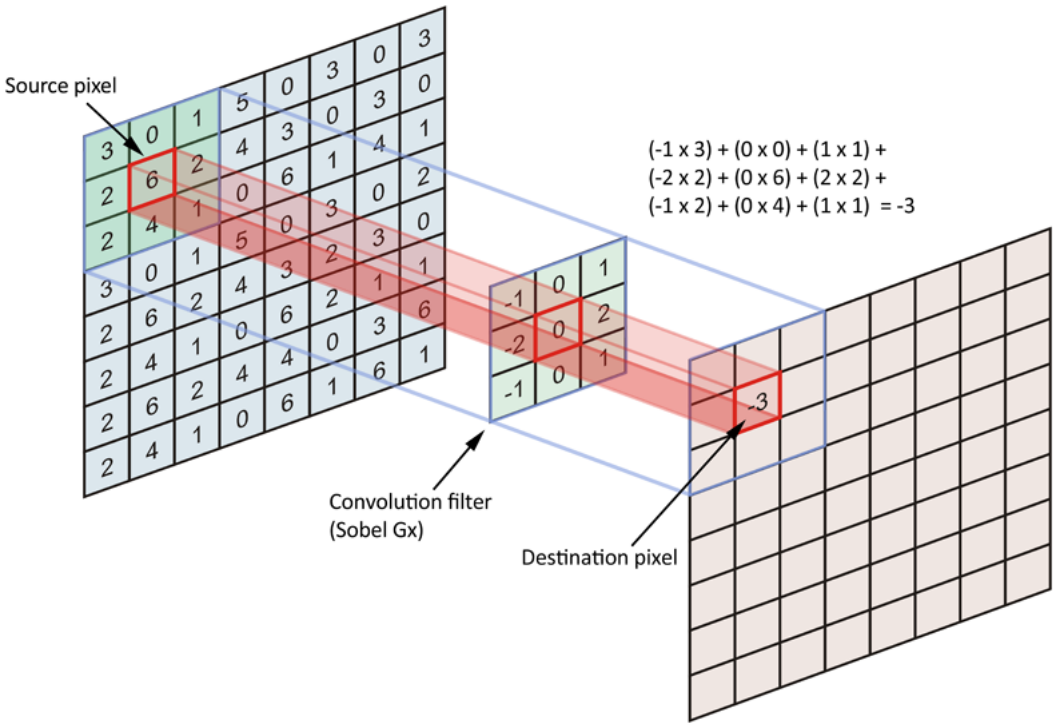

3. ábra. Konvolúció a képfeldolgozásban

A konvolúció műveletének alkalmazásával (megfelelő mátrixokkal) él- és sarokdetektálást tudunk eszközölni a képen. Ez természetesen itt nem részletezett problémákkal nehezedhet valós környezetben (pl. zaj, túl sok detektált él, egymáson fekvő objektumok), de a kapott feldolgozott képen már könnyedén végigfuttaható úgynevezett pattern-search algoritmus (szintén speciális konvolúció), mellyel adott mintázatok helyét tudjuk megállapítani a képen.

Ennek tükrében implementáltunk algoritmusokat, melyek ilyen alapon keresnek mintázatokat, de hatékonyságuk megkérdőjelezhető főként valós környezetben, "standard image processing" kódok között megtalálhatók, illetve az összesítő objektum detektáló dokumentációban részletesebben szerepelnek.

Továbbá több az openCV-ben (képfeldolgozásra szolgáló nyílt forráskódú python és c++ könyvtár) implementált képfeldolgozási algoritmus használhatóságát vizsgáltuk, de mindegyikről elondható, hogy többféle objektum pontos helymeghatározása komplikált, pontatlan, nehezen skálázható, számításigényes.

2.2. Harris sarokdetektálás (Harris Corner Detection)

Egy feature detektáló algoritmus, első lépésként megtalálja a képen a nagy intenzitásgradienssel rendelkező pixeleket, ezek lesznek a feltételezett sarokpontok. Egy csúsztatott ablakkal (változtatható méretű, valójában egyfajta konvolúció) végzi mindezt lokálisan. Általunk a limit állítható, amilyen érték felett saroknak tekinthető egy pont, ezzel látszik is, hogy legtöbb esetben "próbálgatni" kell különböző input képek esetén a kívánt eredmény érdekében, természetesen ez ipari alkalmazásban nem előnyös.

Python programrészlet:

```
import cv2
import numpy as np
```

```
imput_img = 'csatlakozo.jpg'
ori = cv2.imread(imput_img)
image = cv2.imread(imput_img)
gray = cv2.cvtColor(image,cv2.COLOR_BGR2GRAY)
gray = np.float32(gray)
dst = cv2.cornerHarris(gray,2,3,0.04)
dst = cv2.dilate(dst,None)
image[dst>0.01*dst.max()]=[0,0,255]
cv2.imshow('Original',ori)
cv2.imshow('Harris',image)
if cv2.waitKey(0) & 0xff == 27:
    cv2.destroyAllWindows()
```

2.3. Shi-Tomasi sarokdetektáló

Lényegében ugyanaz, mint a Harris-féle, de treshold helyett azt tudjuk beállítani, hogy mennyi sarokpontot szeretnénk megtalálni, jelen alkalmazásnál csupán akkor alkalmazható ha a kameraképet kisebb részekre osztjuk.

2.4. Scale-Invariant Feature Transform - SIFT

Az előző detektáló algoritmusok mindegyike igen nehezen lenne illeszthető a problémára, hiszen nem invariánsak rotációra, a SIFT algoritmus ezekkel szemben robosztusabb, jellegzetes feature-öket talál meg egy képen.

2.5. Speeded-up Robust Features - SURF

A SIFT egy gyorsabb, hatékonyabb verziója.

2.6. BLOB detection

A BLOB jelentése nagy bináris objektum, mely annyit jelent a képfeldolgozásban, hogy a képen egy-egy olyan terület, melyen belül a pixelek hasonló tulajdonságokkal rendelkeznek. Az OpenCV implementációban körökkel van közelítve. Egy körhöz középpont, átlagos pixel intenzitás, szórás és színérték is tartozik.

2.7. Histogram of Oriented Gradients - HoG

A Deep learning előtt az egyik legjobb feature leíró algoritmus volt az objektum detektálásban, gyakorlatilag a képen lokálisan kirajzolja az intenzitás gradiens irányát.

2.8. Binary Robust Independent Elementary Features - BRIEF

SIFT egyik gyorsabb verziója.

2.9. Oriented FAST and Rotated BRIEF - ORB

Kifejezetten arcfelismerésre használják (használták), nagyon gyors feature leíró algoritmus.

2.10. Feature matching

A feature detektáló és leíró algoritmusok után a hagyományos gépi látás esetén egy úgynevezett feature matching algoritmust kell alkalmazni, hogy a megtalált feature-ök közti egyezőséget mérni tudjuk, illetőleg az OpenCV-ben implementált modernebb feature matching algoritmusok a feature térben a két képen egymáshoz legközelebb esőket egymáshoz is rendeli (összeköti), így adható egy treshold érték, amennyi egyező feature esetén tekintjük az objektumokat (képrészleteket) egyező objektumtípusból származónak.

2.11. Konklúzió

Konklúzióként az összes hagyományos képfeldolgozó algoritmusról elmondható, hogy megfelelően optimális körülmények között alkalmas lehet objektumok detektálására, de semmiképp nem tudnak egy automata, adaptív rendzser építőelemeiként funkcionálni, így jelen projektben nem alkalmazzuk őket a továbbiakban.

Részletesebben látható az objektum detektálásról szóló dokumentációban.

3. Manipulátor alrendszer

A manipulátor alrendszert tekintve sikeresen kiválasztottuk a számunkra megfelelőnek vélt SCARA robotkart, melyet biztonságtechnikai szempontoknak megfelelően összeállítottunk a kijelölt tesztelési helyszínen. Egyelőre még nem programoztuk fel, illetve kalibráltuk be a manipulátort, ezt a későbbiekben megtesszük, hogy ennek a vizsgálata, modellezése is megtörténhessen.

4. Optimalizációs alrendszer

Az optimalizációs alrendszer esetében nem történt megemlítendő érdemi előrehaladás.

5. Biztonsági alrendszer

A biztonság elengedhetetlen követelmény ipari környezetben, ez még határozottabban igaz a nem kollaboratív robotokra, hiszen szabályozásuknál fogva ezek nem képesek érzékelni önmagukban az ember jelenlétét, illetve mechanikai teljesítménysűrűsgüknél fogva kis kontaktus esetén is maradandó sérülést okozhatnak.
A biztonság természetesen a tesztelés során is fontos, sőt talán még fontosabb, hiszen előre nem várt esemény is bekövetkezhet, így megfelelően elzártuk a SCARA robotot a külvilágtól.

Ez magában foglalja a bevett fizikai akadályt, mely esetünkben egy fém rács, mely a robot munkaterületén fél méterrel tovább nyúl minden irányban.
A fém rácson belül fényfüggönyt is elhelyeztünk, mely kontaktus esetén azonnal leállítja a robotot.

Ezen bevett biztonsági rendszereken túl a végleges verzióban iparban használatos ütésálló plexilappal is körbe fogjuk venni a manipulátort.
Továbbá a végleges megvalósítás esetén amennyiben a gyártócella biztonságát növeli, szeretnénk a kamerarendszerre egy veszély predikáló applikációt készíteni, mely képes egyrészt detektálni a humán jelenlétet a tiltott helyszíneken, illetőleg egyéb anomáliákat is képes predikálni, például a robotkar útjában lévő objektumokat, melyek esetleges meghibásodáshoz vezethetnek.

6. Grafikus interfész

A grafikus interfésznek alapvetően három fő felületet tervezünk:

- Visszajelzés a SCARA robot és az adagoló állapotáról:

  Ezen a felületen valós időben tudjuk látni a robot 3D-s reprezentációját, illetve numerikus értékeket is láthatunk az egyes koordinátarendszerek aktuális állapotáról.
  Továbbá kameraképet is kaphatunk a robotról és az adagolóró, illetve madártávlatból az egész gyártócelláról.
  Visszajelzést kapunk az objektum detektáló alrendszeren keresztül az éppen a munkaterületen lévő objektumok típusáról és mennyiségéről, a robot által való felvehetőségéről. Amennyiben szeretnénk kameraképet is kérhetünk a detektálás vizuális visszajelzésével együtt.

- Statisztikai visszajelzés:

  Tetszőleges időre visszamenőleg megtekinthetjük a gyártócellához tartozó adatokat: ciklusidő, elkészített termékek típusai, darabszáma, SCARA robot által vétett hibás objektum áthelyezések száma, fészekbe történő behelyezési hibák, átlagos felvehető objektumok számossága, stb. Ezen adatokat tetszőleges szűrhetjük az interfészen belül.

Kijelzésre kerülnek továbbá az optimalizációs alrendszer által javasolt módosítások predikált értékek, esetleges hibalehetőségek.

- Konfigurációs felület:

  Ide a megfelelő autentikáció után belépve módosítható a gyártócella minden beállítása azaz az aktuális manipulátorhoz tartozó módok, optimalizációs paraméterek, kiválasztott áthelyezni kívánt objektum típusa, stb.

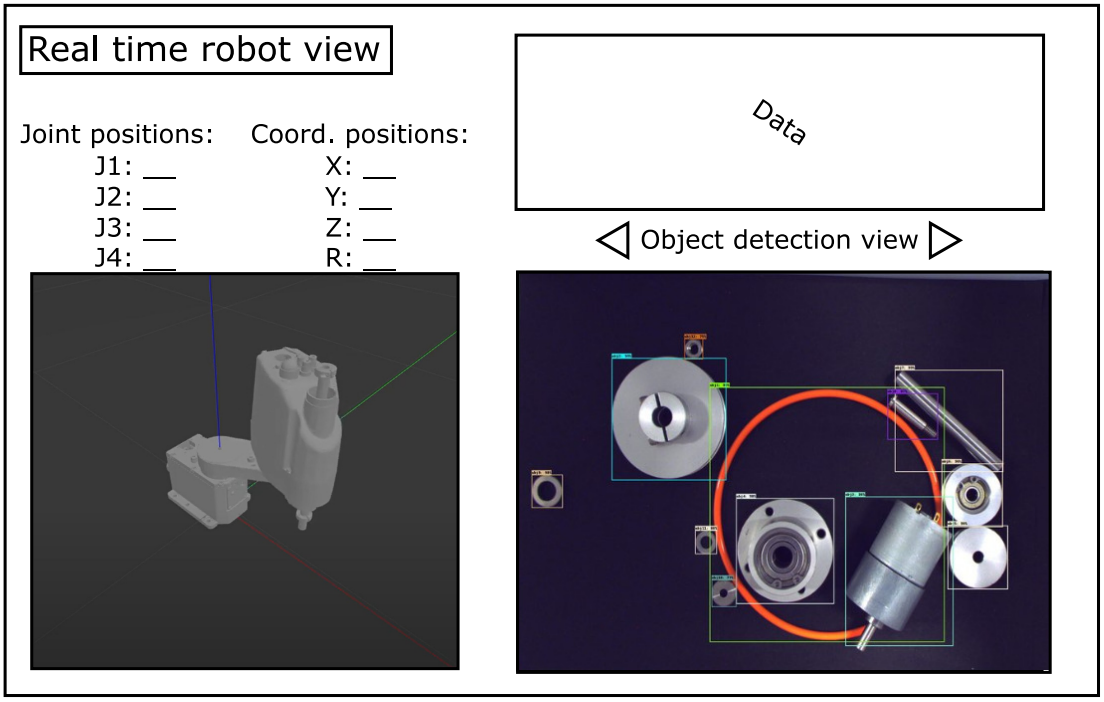

4. ábra. 1. Grafikus rész mockup

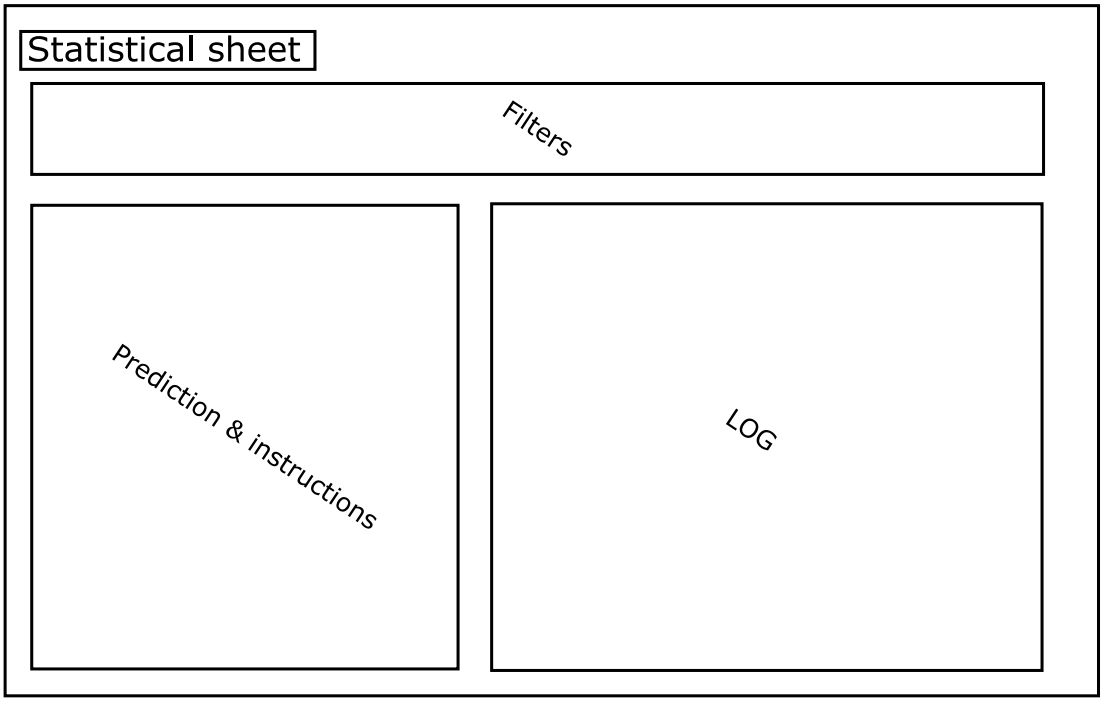

5. ábra. 2. Grafikus rész mockup